Predicción del riesgo de retraso en vuelos comerciales de Estados Unidos

Jerónimo Acosta Acevedo, Santiago Gomez, Alejandro Quintero Moreno, Victor Daniel Delgado

Problema del negocio.

La operación del transporte aéreo depende de la coordinación de vuelos, aeropuertos, aerolíneas y horarios. Cuando un vuelo presenta un retraso, las consecuencias pueden extenderse a las conexiones de los pasajeros, la organización de recursos operativos y el cumplimiento de los itinerarios programados. Por esta razón, la puntualidad constituye una variable relevante tanto para la gestión de las aerolíneas y aeropuertos como para la experiencia de los viajeros.

Aunque existe una gran cantidad de información histórica sobre los vuelos comerciales, conocer cuáles se retrasaron en el pasado no necesariamente permite anticipar cuáles podrían presentar problemas en una nueva jornada de operación. Para quienes deben supervisar múltiples vuelos, resulta especialmente útil contar con una herramienta que permita identificar de manera anticipada aquellos que requieren mayor atención.

En respuesta a esta necesidad, el proyecto propone **desarrollar una solución analítica para estimar, antes de la salida, la probabilidad de retraso de los vuelos comerciales domésticos en Estados Unidos**. Se plantea considerar como retraso significativo una salida de 15 minutos o más después del horario programado, de acuerdo con la clasificación disponible en los registros del Bureau of Transportation Statistics (BTS).

La estimación se realizará a partir de información que pueda conocerse previamente, como la aerolínea, los aeropuertos de origen y destino, la fecha, el horario programado, la distancia de la ruta y los patrones históricos de operación. Se utilizarán registros correspondientes al período 2022–2026, de acuerdo con su disponibilidad y calidad. La fuente principal propuesta es la base Reporting Carrier On-Time Performance del BTS, mientras que otras fuentes públicas podrán evaluarse como complementos si aportan información compatible con el objetivo.

La solución estará dirigida principalmente a apoyar el análisis y la priorización operativa de vuelos con mayor riesgo de retraso. No se pretende determinar con certeza si un vuelo saldrá tarde, ni establecer las

causas específicas de cada retraso, sino generar una estimación que permita tomar decisiones con mejor información.

De esta manera, el proyecto busca transformar datos históricos en información predictiva y accesible, integrando aprendizaje automático, procesamiento de grandes volúmenes de datos y herramientas de visualización para atender una necesidad concreta del sector aeronáutico.

Impacto de la solución

El principal impacto esperado consiste en facilitar la identificación anticipada de vuelos con mayor probabilidad de presentar retrasos, convirtiendo información histórica en un recurso útil para el seguimiento y la planificación operativa.

La solución propuesta permitirá:

Identificar vuelos de mayor riesgo: ofrecer una estimación individual de la probabilidad de retraso que permita priorizar los vuelos que requieren mayor seguimiento.

Reconocer patrones operativos: analizar cómo varía el riesgo entre aerolíneas, aeropuertos, rutas, horarios y períodos del año.

Apoyar la toma de decisiones: presentar información que pueda servir como insumo para actividades de supervisión, planificación y comunicación preventiva.

Facilitar el acceso a los resultados: integrar las predicciones y los principales hallazgos en una herramienta de visualización que permita explorar la información de manera clara.

Como resultado final se espera desarrollar un modelo predictivo evaluado con datos históricos y un prototipo de visualización que muestre el riesgo estimado de retraso, junto con información relevante para su interpretación.

El desempeño del modelo se medirá mediante métricas de clasificación, prestando especial atención a su capacidad para identificar vuelos que efectivamente presentan retrasos y a la cantidad de alertas incorrectas que pueda generar.

Se espera demostrar el valor de combinar distintas técnicas de ciencia de datos para apoyar decisiones operativas. No obstante, los beneficios planteados son potenciales y deberán distinguirse de impactos

efectivamente comprobados. El proyecto no asumirá reducciones de retrasos, ahorros económicos o mejoras operativas sin evidencia que permita sustentarlas.

Marco Teórico (máx 1 página)

Definiciones de conceptos pertinentes a tu problema u objetivo.

Para la realización de nuestro proyecto, pondremos en práctica conceptos vistos durante las 3 materias críticas de la línea de énfasis en Ciencia de Datos: *Aprendizaje Automático*, *Almacenamiento y Procesamiento de grandes datos* y *Visualización de datos*.

El Aprendizaje Automático es "un subconjunto de la inteligencia artificial que permite que un sistema aprenda y mejore de forma autónoma con redes neuronales y aprendizaje profundo, sin necesidad de una programación explícita, a través del análisis de grandes cantidades de datos" (Google Cloud, s. f.). De esta materia tomamos en cuenta el **entrenamiento del modelo**, el cual debe ser entrenado de tal forma que logre predecir a futuro la probabilidad de retraso de un vuelo en EE.UU. La calidad del modelo se mide con varias métricas, entre ellas la **precisión**, **recall** y **F1** que miden calidad a partir de un umbral; **ROC-AUC/PR-AUC** dependiendo de la ocurrencia; y **Brier score/Log loss** para medir la calidad de las predicciones. Estas métricas nos ayudan a concluir si el modelo que estamos desarrollando cumple con la pregunta de negocio.

El modelo como tal que estaremos usando es **LightGBM** con una **regresión logística como línea base** (usamos regresión logística ya que estamos calculado las probabilidades de eventos categóricos) y una **calibración de probabilidades** al final. Cabe resaltar que dependiendo del almacenamiento de estos datos, el modelo puede cambiar a un simple **HistGradientBoostingClassifier** de scikit-learn o un **GBT de Spark MLlib.**

Como referencias previas, nos estaremos basando en estudios similares que han sido realizados en otras partes del mundo. Por ejemplo, el estudio realizado por Shayan Zulfiqar, **Flight Delay Risk Analysis**, busca hacer un análisis de la probabilidad de perder un vuelo en India. Este estudio también utilizó **LightGBM** como su modelo, por lo que tenemos sólidas bases.

Estos datos nos ayudan a realizar un proyecto que verdaderamente logre solucionar el problema de negocio con un alto rango de exactitud y rigor.

Descripción de datos a utilizar

Dataset 1: Reporting Carrier On-Time Performance (BTS)

Descripción:

Base de datos del Bureau of Transportation Statistics (BTS) del Departamento de Transporte de EE.UU. Reúne, mes a mes, los vuelos domésticos programados por las aerolíneas que reportan al BTS. Cada registro corresponde a un vuelo e incluye la aerolínea, los aeropuertos de origen y destino, la fecha, los horarios programados y reales, los minutos de retraso, así como los desvíos y la distancia. Al tener cada mes cientos de miles de vuelos, el volumen de datos alcanza varios millones de registros.

Variable Objetivo Potencial

DepDel15 (Indicador de retraso en la salida)

Variables de prediccion:

FlightDate (Fecha del vuelo)
Year, Quarter, Moth, DayofMoth, DayofWeek (Componentes temporales)
Origin (Aeropuerto de origen)
Dest (Aeropuerto de destino)
OriginState, DesState (Estado de origen y de destino)
CRSDepTime (Hora de salida programada)
DepTimeBlk (Bloque horario de salida programada)
CRSArrTime (Hora de llegada programada)
CRSElapsedTime (Duracion programada del vuelo en minutos)
Distance (Distancia de la ruta en millas)
Flight_Number_Reporting_Airline (Numero de vuelo)
Tail_Number (Matricula de la aeronave)

Variables de control:

Cancelled
CanellationCode
Diverted

Variables no predictoras (Cálculo de patrones históricos y filtros)

DepTime, DepDelay, DepDelayMinutes, DepartureDelayGroups, TaxiOut, WheelsOff, ArrDelay, ArrDel15, CarrierDelay, WeatherDelay, NASDelay, SecurityDelay, LateAircraftDelay

Anonimización
SI___ | NO **X**

¿Esta base de datos es pública?
SI **X** | NO___

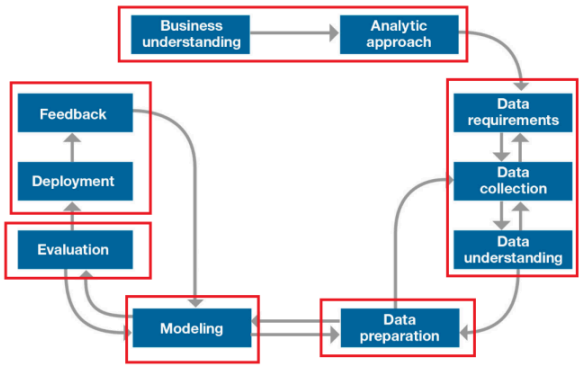
DataSet 2: US Domestic Flight Arrival Delay, Full Pipeline Dataset (2018-2024)
Descripción:
Conjunto de datos abierto publicado en Zenodo (DOI 10.5281/senodo.20489892) por el grupo 5 del capítulo DSC 288R de la maestría en ciencia de datos de UCSD. Reúne los registros del BTS de vuelos domésticos de EE. UU con observaciones meteorológicas de NOAA (estaciones ASOS) e indicadores de feriados federales. Cubre 2018-2044. Se propone como complemento de la base provincial del BTS para evaluar el aporte del clima en 2022-2024 sin construir la unión desde cero y para evaluar modelos que cubren el periodo completo propuesto.

¿Esta base de datos es pública?
SI X | NO___

Metodología a emplear: ASUM-DM

El proyecto seguirá **ASUM-DM** (*Analytics Solutions Unified Method for Data Mining*), una extensión de CRISP-DM que conserva sus fases e incorpora de forma explícita la gestión del proyecto, la iteración entre etapas y la puesta en operación de la solución.

Así aplicaremos el modelo:



Ref: Garrido Asenjo, 2025

Entendimiento del negocio, problema o hipótesis: Quienes supervisan muchos vuelos no pueden anticipar cuáles tendrán problemas, aunque exista abundante información histórica. El objetivo es **estimar, antes de la salida, la probabilidad de que un vuelo doméstico de EE. UU. se retrase 15 minutos o más**.

Enfoque analítico: Como el objetivo es una probabilidad, el problema se plantea como una **clasificación binaria con salida probabilística**. Se usará aprendizaje supervisado, con una regresión logística como línea base y gradient boosting (LightGBM) como modelo principal. El éxito se medirá con métricas de calidad de la probabilidad (Brier score, log loss y calibración), de discriminación (ROC-AUC y PR-AUC) y por umbral (precisión, recall y F1).

Requisitos de datos: Se necesitan registros históricos de vuelos con su horario programado, aerolínea, origen, destino, distancia y resultado de puntualidad, además de variables externas como el clima y los feriados. Solo se permiten variables conocidas antes de la salida, y la cobertura debe ser suficiente para construir patrones históricos y respetar el orden cronológico.

Entendimiento de los datos: Se revisará el diccionario de variables, la cobertura temporal, la calidad y la tasa base de retrasos. Se clasificarán las variables en predictoras, de control y no predictoras, que quedan excluidas para evitar fuga de información. El análisis exploratorio (**EDA**) se hace en esta etapa: distribución del retraso por aerolínea, aeropuerto, hora y temporada, valores atípicos y posibles fugas.

Preparación de los datos: Lectura por columnas o por lotes debido al volumen. Revisión de nulos, duplicados e inconsistencias, y filtrado de vuelos cancelados y desviados. Construcción de la variable objetivo y de variables temporales (mes, día de la semana, bloque horario). Construcción de patrones

históricos (tasa de retraso por aeropuerto, ruta, aerolínea y hora, e historial de la aeronave) usando solo vuelos anteriores a cada salida. Integración del clima con un corte previo a la salida, documentado.

Modelado: Se entrenará la **regresión logística** como línea base y **LightGBM** como modelo principal, por su buen desempeño con datos tabulares, variables categóricas de muchos valores y grandes volúmenes. No se rebalancearán las clases, para no distorsionar las probabilidades, y se aplicará calibración (isotónica o Platt) sobre el tramo de validación. Se fijarán semillas y se versionará el código para garantizar reproducibilidad.

Evaluación: Se mencionó anteriormente. La evaluación se hace sobre el tramo de prueba cronológico:

- **Calidad de la probabilidad:** Brier score, log loss y curva de calibración (con ECE).
- **Discriminación:** ROC-AUC y PR-AUC.
- **Métricas por umbral:** precisión, recall, F1 y matriz de confusión, con un umbral que responda al costo de las falsas alarmas frente a los retrasos no detectados.
- **Comparación** con la línea base y análisis por subgrupos (aerolínea, aeropuerto, franja horaria, temporada) para detectar dónde el modelo falla o está mal calibrado.

Despliegue: El modelo calibrado se desplegará en un entorno en la nube, apoyado en lo visto en la materia *almacenamiento y procesamiento de grandes datos*. Esto puede incluir (**pero no está atado a**) datos en parquet sobre almacenamiento en la nube, preparación de variables y generación de predicciones en lote para los vuelos programados, y un tablero de visualización que muestre el riesgo estimado, los principales patrones y la información necesaria para interpretarlos.

Retroalimentación. Una vez en operación, se monitorea el desempeño en el tiempo y se recogerán las observaciones de los usuarios. Con eso se decidirá si hay que recalibrar o reentrenar el modelo, o ajustar variables o umbrales, volviendo al modelado y cerrando el ciclo.

Lista de actividades a realizar en el proyecto para lograr el objetivo:

Configuración del Entorno, Repositorio y Arquitectura de Referencia:

- Configuración del repositorio de código versionado (Git) y estructura del proyecto.
- Fijación de entorno reproducible (manejo de dependencias y semillas para garantizar reproducibilidad).
- Definición y montaje de la arquitectura de referencia para la canalización (*pipeline*) de datos y modelos.

Adquisición, Depuración e Integración de Datos:

- Descarga e ingesta de los registros BTS (2022-2026) y el dataset de Zenodo (clima/feriados).
- Depuración de datos: filtrado de vuelos cancelados/desviados y resolución de nulos o inconsistencias.
- Conversión del volumen masivo a formato Parquet y optimización de lectura por bloques/columnas.

Análisis Exploratorio de Datos (EDA) y Prevención de Fuga de Información:

- Análisis exploratorio de la tasa base de retrasos por aerolínea, aeropuerto, bloque horario y temporalidad.
- Auditoría estricta de variables para descartar variables posteriores al despegue (variables de control y no predictoras) y evitar *data leakage*.

Ingeniería de Características y Patrones Históricos Acumulados:

- Construcción de patrones históricos (tasas previas de retraso por ruta, aerolínea y matrícula de aeronave) garantizando que solo usen vuelos estrictamente anteriores.
- Integración de variables externas (clima/festivos) aplicando el punto de corte (*cutoff*) temporal formalizado previo a la salida.

Modelado, Balance de Clases y Calibración:

- División cronológica del conjunto de datos (Entrenamiento, Validación y Prueba).
- Entrenamiento del modelo de Regresión Logística como línea base.
- Entrenamiento y ajuste de hiperparámetros de LightGBM (Gradient Boosting) manteniendo la distribución original de clases.
- Calibración de probabilidades (Isotónica / Platt Scaling) sobre la partición de validación.

Evaluación Metrológica y Análisis Operativo por Subgrupos:

- Evaluación de calidad probabilística (Brier score, Log loss, calibración ECE) y discriminación (ROC-AUC, PR-AUC).
- Selección del umbral de decisión según el impacto de falsas alarmas vs. retrasos no detectados.
- Análisis comparativo de desempeño por subgrupos (aerolíneas, aeropuertos, franjas horarias y temporadas).

Desarrollo del Prototipo de Visualización y Flujo de Inferencia:

- Construcción del *pipeline* para la generación de predicciones por lotes sobre vuelos programados.

- Desarrollo del prototipo interactivo (Dashboard) para la priorización y seguimiento del riesgo de retraso.

Pruebas Integrales, Documentación y Difusión:

- Pruebas de integración del flujo completo (datos -> modelo -> visualización).
- Consolidación de la documentación final, código versionado y manual de ejecución.
- Preparación del material de difusión y presentación final de resultados del proyecto.

Cronograma por semana del proyecto

	W1	W2	W3	W4	W5	W6	W7	W8
1. Entorno, Repositorio y Arquitectura de Referencia	x							
2. Adquisición, Depuración y Conversión a Parquet	x	x						
3. Análisis Exploratorio (EDA) y Filtro de Fuga de Información		x	x					
4. Ingeniería de Características y Patrones Históricos			x	x				
5. Modelado (Regresión Logística y LightGBM) y Calibración				x	x			
6. Evaluación Metrológica, Umbrales y Análisis por Subgrupos					x	x		
7. Prototipo de Dashboard y Generación de Predicciones en Lote						x	x	
8. Pruebas Integrales, Documentación Final y Difusión							x	x

Métodos, Modelos, aplicación, tecnología en cada una de las materias del proyecto integrador 1

Modelos/técnicas/tecnologías a usar:

Curso 1: SI7009/SI6002 Aprendizaje Automático

- Modelaje supervisado
- Metricas de Discriminación: ROC-AUC y PR-AUC.
- Modelo Gradient Boosting
- Métricas por umbral: Precisión, Recall, F1 y Matriz de confusión.
- Regresiones Logísticas
- Preparación de datos

Modelos/técnicas/tecnologías a usar:
Curso 2: SI7006/SI6003 Almacenamiento y Procesamiento de grandes datos

- Falta por ver

Modelos/técnicas/tecnologías a usar:
Curso 2: SI7007/SI6004 Visualización de datos

- Falta por ver

Consideraciones requeridas para el desarrollo del proyecto (si las hay):

Condiciones sobre los datos:
Solo se permiten variables conocidas antes de la salida para las predicciones, cualquier variable posterior queda excluida, El equipo definirá y documentará un corte previo a la salida de ser necesario para la evaluación del aporte del clima u otras variables en el desarrollo.
La partición entrenamiento/prueba respetara el orden cronológico.
Se construirán patrones históricos sólo con datos anteriores a cada vuelo, el dataset principal provee el volumen temporal suficiente para la construcción de los patrones históricos.
Se revisarán nulos, duplicados, inconsistencias en el flujo de los datos y se realizará la limpieza necesaria para la correcta evaluación de los modelos sobre los datos.
Se garantiza que los datos no contienen información personal y la información sobre códigos de vuelos corresponden a aeronaves y es información pública.

Condiciones sobre la tecnología:

- Solo entre enero de 2022 y julio de 2025 hay más de 20 millones de vuelos, debido al gran volumen de datos se trabajara con parquet y lectura por columnas o por lotes.
- Se sugiere Python con pandas y scikit-learn. Se tiene en cuenta la migración de segmentos del proyecto a lenguajes como R de demostrarse que hay una mejora en el rendimiento o la carga computacional.
- El código debe estar documentado, versionado de ser posible con semillas fijas y entorno reproducible.

Restricciones

- El periodo corresponde de 2022 a 2026.

- Los vuelos El alcance se limita a los vuelos domésticos de EE. UU de aerolíneas que reportan al BTS.
- El modelo solo puede usar información conocida antes de la salida para generar predicciones.
- La estimación es sobre la probabilidad de un retraso significativo, la duración y su causa son consideraciones secundarias para el objetivo del proyecto.

Riesgos

- La fuga de información en datasets complementarias es una posibilidad. Si el dataset complementario no cuenta con la documentación sobre como se calcularon los rezagos el equipo debe hacer la revisión adecuada antes de usarlo de apoyo.
- Usar datasets "empaquetados" como fuente de datos principal por encima de los datos oficiales corresponde un riesgo de calidad de datos.
- Las políticas del acceso a la información pueden cambiar o limitarse, se mantendrán copias locales de los datos siguiendo los parámetros establecidos para su uso al momento de la descarga.

Propiedad Intelectual y Derechos de autor.

- Para BTS, datos publicados por una agencia del gobierno de EE. UU. con nivel de acceso público según el catálogo del DOT. Se citará la fuente y se confirmaran los términos de uso en el sitio.
- Para Zenodo, liencia CC- 1.0 (Dominio publico) Se citara igualmente por DOI y se acreditara a sus autores.
- Se compartirán código y scripts de descarga, Los datos solo se redistribuyen si los términos de cada fuente lo permiten.
- La titularidad queda por definirse según los acuerdos del equipo y de la institución.

Referencias bibliográficas

- Google Cloud. (s. f.). *¿Qué es el aprendizaje automático? Tipos y usos*. Recuperado el 12 de octubre de 2026 de https://cloud.google.com/learn/what-is-machine-learning?hl=es-419
- shayanzk. (s. f.). *Flight delay risk analysis* [Cuaderno de código]. Kaggle. https://www.kaggle.com/code/shayanzk/flight-delay-risk-analysis
- Garrido Asenjo, N. (2025, 1). *La metodología ASUM-DM en ciencia de datos*. LinkedIn. https://www.linkedin.com/pulse/la-metodolog%C3%ADa-asum-dm-en-ciencia-de-datos-garrido-asenjo-jgywe/

- Bureau of Transportation Statistics. (n.d.). *Reporting carrier on-time performance (1987–present)* [Data set]. U.S. Department of Transportation. Retrieved October 12, 2026, from https://www.transtats.bts.gov/DL_SelectFields.asp?gnoyr_VQ=FGJ
- Group 5, DSC 288R Capstone, UCSD MDS. (2026). *US domestic flight arrival delay — Full pipeline dataset (2018–2024)* (Version v2) [Data set]. Zenodo. https://doi.org/10.5281/zenodo.20489802
-